Data Frames

Rodrigo Negrete Pérez

January 18, 2022

Section 1

Introducción

Introducción

El hilo conductor del curso es la pregunta de la causalidad

- No cualquier tipo de pregunta causal
  - ¿Cuál es el efecto de A sobre B?
- A manera de ejemplo: efecto del la educación superior sobre el salario

Educación y salario

- Parece intuitivo, pero pueden pasar muchas cosas en medio de la relación
- ¿Cuál es el efecto... de le educación?
- Podemos planter un modelo: con datos simulados podemos saber qué estima nuestro modelo
  - Si estimamos con sesgo
  - ventajas y desventajas

Section 2

Potential Outcomes

Potential Outcomes

Suponemos que la entidad tiene dos posibles resultados: bajo tratamiento y sin tratamiento (control)

- Si Rodrigo va a la universidad, su salario sería de 80k mensuales
- Si no va a la universidad, su salario sería de 25k

Entonces, denotamos $Y_{0R} = 25$ al outcome bajo control y $Y_{1R} = 80$ al outcome bajo tratamiento

Problema fundamental de la inferencia causal

El problema es que solo observamos uno de los dos posibles potential outcomes:

- Si Rodrigo va a la uni, observaré Y_{1R}
- Si no, Y_{0R}

$$Y_i = \begin{cases} Y_{1i}, & \text{si } t = 1 \\ Y_{0i}, & \text{si } t = 0 \end{cases} \tag{1}$$

Entonces, podemos escribir la Y observada como

$$Y_i = Y_{0i} + (Y_{1i} - Y_{01})T_i$$

Generación de P.O.

Vamos a generar los Potential Outcomes

Supongamos que:

- $Y_{0i}\ N(30, 10)$
- $Y_{1i}\ N(50, 35)$

```
set.seed(2022)
n<-10000
i<-1:n
y0<-rnorm(n, 30, 10)
y1<-rnorm(n, 50, 35)
df<-data.frame(i,y0,y1)
```

```
##   i         y0       y1
## 1 1 39.0014199 88.53769
## 2 2 18.2665423 58.19311
## 3 3 21.0251464 31.82775
## 4 4 15.5549860 33.65446
## 5 5 26.6898642 68.54422
## 6 6  0.9937101 61.58160
```

Asignación del tratamiento

Tenemos que asignar el tratamiento

- Podríamos hacerlo con un vector de 1 y 0, y que t sea equiprobable: simple random assignment
- Podríamos asignar t a mitad de la muestra: complete random assignment
- Para complete ra es más práctico usar el paquete randomizr: complete_ra( )

```
library(randomizr)
```

% latex table generated in R 4.1.0 by xtable 1.8-4 package % Tue Jan 18 21:34:48 2022

	i	y0	y1	t
1	1	39.00	88.54	1
2	2	18.27	58.19	1
3	3	21.03	31.83	0
4	4	15.55	33.65	1
5	5	26.69	68.54	0
6	6	0.99	61.58	0

Así, podemos añadir la Y observada

```
df<-mutate(df,y_observada=y0+(y1-y0)*t)
```

% latex table generated in R 4.1.0 by xtable 1.8-4 package % Tue Jan 18 21:34:48 2022

	i	y0	y1	t	y_observada
1	1	39.00	88.54	1	88.54
2	2	18.27	58.19	1	58.19
3	3	21.03	31.83	0	21.03
4	4	15.55	33.65	1	33.65
5	5	26.69	68.54	0	26.69
6	6	0.99	61.58	0	0.99

Section 3

Efectos Causales

Efecto Causal Individual

Cuando tenemos ambos P.O. podemos calcular el **Efecto Causal Individual** (δ_i) tomando la diferencia entre Y_{1i} y Y_{0i}

$$\delta_i = Y_{1i} - Y_{0i}$$

- Por ejemplo, decimos que el efecto de la uni en Rodrigo es de $\delta_R = 80 - 25$ pesos mensuales
- Hay una gran heterogeneidad en los efectos causales individuales
- Hay 5 individuos cuyo salario es mayor sin universidad

```
df<-mutate(df, delta=y1-y0)
```

% latex table generated in R 4.1.0 by xtable 1.8-4 package % Tue Jan 18 21:34:48 2022

	i	y0	y1	t	y_observada	delta
1	1	39.00	88.54	1	88.54	49.54
2	2	18.27	58.19	1	58.19	39.93
3	3	21.03	31.83	0	21.03	10.80
4	4	15.55	33.65	1	33.65	18.10
5	5	26.69	68.54	0	26.69	41.85
6	6	0.99	61.58	0	0.99	60.59

Efecto Causal Promedio

- Nos importa el efecto que tiene la uni en general: el efecto promedio

$$ATE = E[Y_{1i} - Y_{0i}] = E[\delta_i]$$

- Basta con tomar el promedio de los efectos causales individuales, pero para toda la muestra.

Efecto promedio sobre los tratados

- De igual manera, podemos calcular el efecto promedio, pero sobre los tratados

$$ATT = E[Y_{1i} - Y0i | T_i = 1]$$

- Es calcular el ATE, pero solo para aquellos que fueron tratados.

Efecto promedio sobre los controles

- Análogamente, el ATC es el ATE, pero consideramos solo a aquellos que fueron controles

$$ATC = E[Y_{1i} - Y0i | T_i = 0]$$

- Con datos generados es muy fácil calcular los efectos causales
- Tomamos los efectos causales individuales, los dividimos en subconjuntos, y luego calculamos promedios
- En R, las funciones **filter()** y **with()** nos van a ser muy útiles

```
ate<-with(df, mean(delta))
att<-with(filter(df, t==1), mean(delta))
atc<-with(filter(df, t==0), mean(delta))
```

- Obetenemos que el ATE=20.5874983
  - ATT=20.3810284
  - ATC=20.7939683

Contraste Ingenuo

- Sin embargo, el investigador no puede observar estos efectos. Ninguno es observable
- Lo que el investigador puede observar es el Contraste ingenuo: el promedio del outcome para los tratados menos el promedio del outcome para los no tratados

$$CI = E[Y_{1i}|T_i = 1] - E[Y_{0i}|T_i = 0]$$

- En nuestro df definimos las y_observada(s)
- Para calcular el CI, basta calcular el promedio de las y_observadas de los que fueron tratados, y restarle el promedio de las y_observadas de los controles.

```
ci<-with(filter(df, t==1),
         mean(y_observada))-
  with(filter(df, t==0),
          mean(y_observada))
```

- Obtenemos un CI=20.3875545, el cual es muy parecido al ATE=20.5874983
- Entonces, ¿por qué tanto problema?

Section 4

Simulaciones

Virtudes de las simulaciones

- Los datos que generamos provienen de una distribución normal.
- Podemos calcular muchas cosas usando cálculo diferencial.
  - Por ejemplo, ya sabíamos que el ATE iba a ser de 20
  - Sin embargo, por el elemento aleatorio no dio 20, sino 20.5874983
  - Pero no siempre será tan fácil como aplicar las propiedades de la normal.
- Alternativamente al cálculo diferencial, podemos hacer el cálculo muchas muchas veces y ver hacia dónde tiende

- Por ejemplo, ¿nuestro CI coincidió con el ATE por el elemento aleatorio? ¿Fue una casualidad?
- ¡Simulemos! Hagamos el mismo cálculo, pero varias veces: para cada df tomemos el ATE y el CI.
- En R, podemos hacerlo fácilmente con un FOR loop.
- Hagámoslo unas 5000 veces

```
numrep<-5000
```

- Preparemos el loop
- Luego podremos mover el número de repeticiones y la cantidad de individuos

```
set.seed(2022)
#semilla
numrep<-5000
n<-10000

ate_estimates<-NULL #vectores vacios
ci_estimates<-NULL  # para guardar datos
```

```
for (i in 1:numrep) {
  # Creacion df
df<-data.frame(i=1:n,
               y0=rnorm(n, 30, 10),
               y1=rnorm(n, 50, 35),
               t=complete_ra(n)) %>%
  mutate(y_observada=y0+(y1-y0)*t,
         delta=y1-y0)

  # Calculo efectos causales
# Debemos guardarlos como entrada en vectores
ate_estimates[i]<- with(df, mean(delta))

ci_estimates[i]<- with(filter(df, t==1),
         mean(y_observada))-
  with(filter(df, t==0),
          mean(y_observada))
}
```

- Hagamos un análisis visual
- Hagamos un histograma para los ATE's y otro para los CI's

```
ggplot()+
  geom_histogram(aes(ate_estimates),
                 fill='red', alpha=.5,
                 bins = 100)+
  geom_histogram(aes(ci_estimates),
                 fill='blue', alpha=.5,
                 bins=100)+
  geom_vline(xintercept = mean(ate_estimates),
             color='red')+
  geom_vline(xintercept = mean(ci_estimates),
             color='blue')+
  xlab('')
```

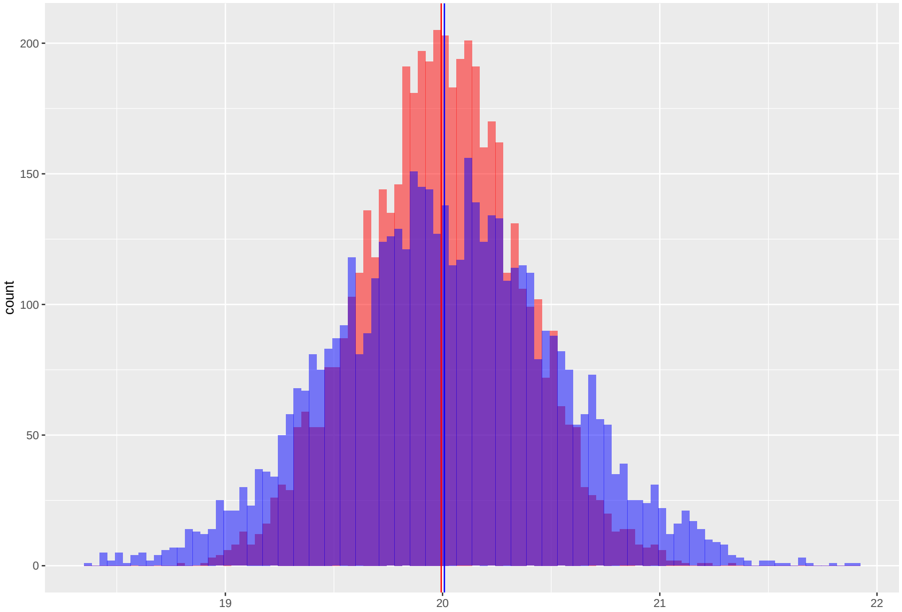
count
200
150
100
50
0
19
20
21
22

- Tratemos de graficar las diferencias

```
error_estimates<-ate_estimates-
  ci_estimates
```

- Hacemos un vector porque ggplot requiere un df

```
ggplot()+
  geom_histogram(aes(x=error_estimates),
                 bins = 100)+
  geom_vline(xintercept =
               mean(error_estimates))
```

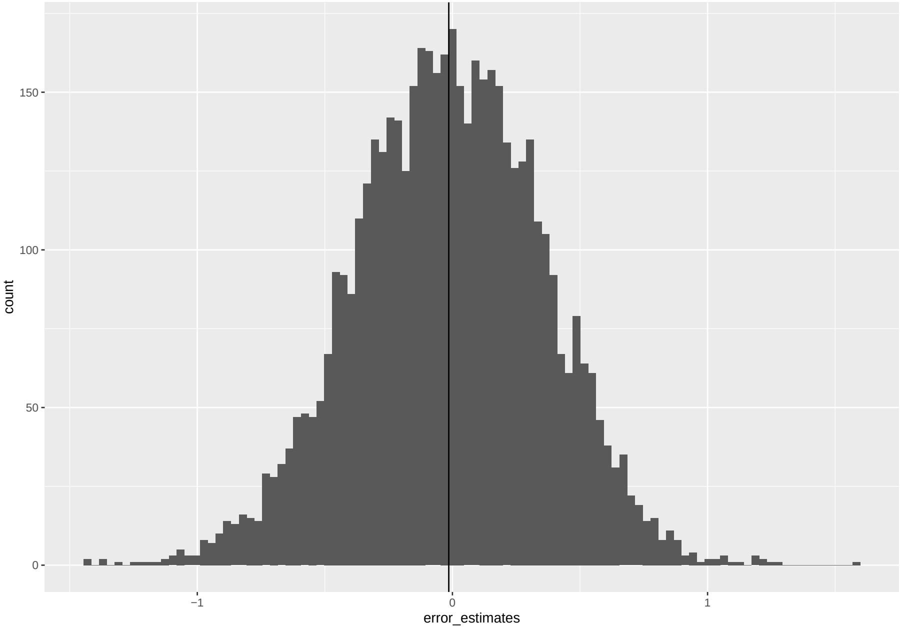
150
100
50
0
count
−1
0
1
error_estimates

- Podríamos concluir que el CI estima insesgadamente el ATE...
  peeeroo
- Nos apoyamos en algunos SUPUESTOS

Section 5

Sesgo de selección

Unconfoundedness

En el centro de todas las estrategias de identificación yace el supuesto de **Unconfoundedness**

- Una vez condicionemos sobre todo lo que tenemos que controlar, la asignación del tratamiento es cuasialeatoria
- La asignación del tratamiento no puede depender de los Potential Outcomes
- Si los individuos se tratan porque creen que el tratamiento les va a funcionar, se estan **autoseleccionando**.

Asignación aleatoria del tratamiento

- La asignación aleatoria del tratamiento (junto con la Ley de los Grandes Números) garantiza que la asignación aleatoria del tratamiento no depende de los P.O.
- En nuestras simulaciones, la asignación de t siempre fue aleatoria

Autoselección

- Repitamos las simulaciones, pero cambiemos la asignación de t
- Hagamos que t dependa de los P.O.

- La Educación universitaria es costosa
  - Costos monetarios
  - Costos de oportunidad
  - Tiempo
- Supongamos que solo se tratan aquellos para los que la uni les mejora considerablemente el salario mensual
- Supongamos que:

$$T_i = \begin{cases} 1, & \text{si } Y_{1i} - Y_{0i} > 10 \\ 0, & \text{e.o.c.} \end{cases} \tag{2}$$

```r
set.seed(2022)
#semilla
numrep<-5000
n<-10000

ate_estimates<-NULL #vectores vacios
ci_estimates<-NULL  # para guardar datos
```

```
for (i in 1:numrep) {
  # Creacion df
df<-data.frame(i=1:n,
               y0=rnorm(n, 30, 10),
               y1=rnorm(n, 50, 35)) %>%
  mutate(t=ifelse(y1-y0>10,1,0), #Cambiamos t
    y_observada=y0+(y1-y0)*t,
         delta=y1-y0)

  # Calculo efectos causales
# Debemos guardarlos como entrada en vectores
ate_estimates[i]<- with(df, mean(delta))

ci_estimates[i]<- with(filter(df, t==1),
         mean(y_observada))-
  with(filter(df, t==0),
          mean(y_observada))
}
```

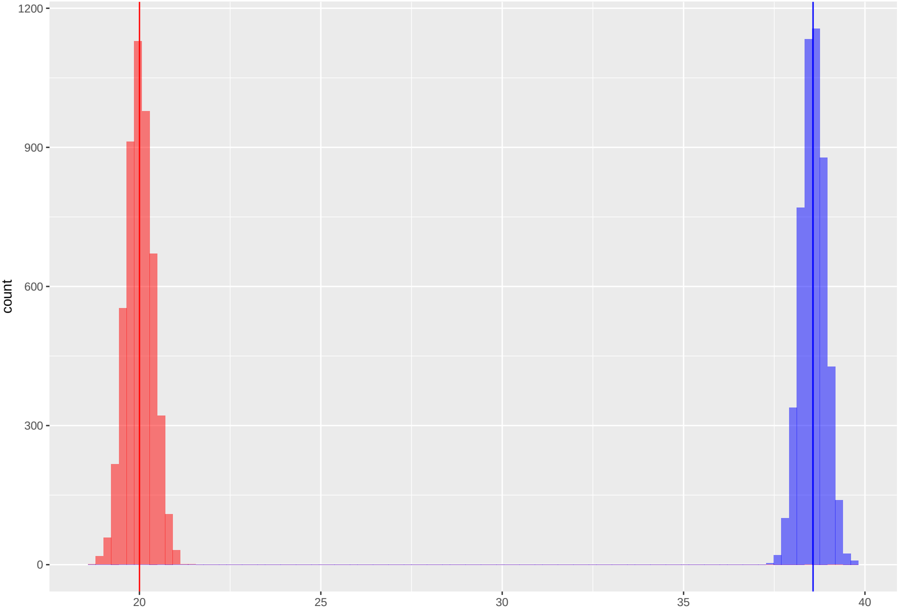
count
1200
900
600
300
0
20
25
30
35
40

- La diferencia es dramática:
  - El promedio de nuestros ATE's es 20.0008954, mientras que el promedio de los CI's es 38.5690034
- Nuestro CI tiende a sobreestimar el efecto real de la uni (y por mucho)
- Extrapolando: si los individuos se autoseleccionan, el CI va a estar sesgado
- La dirección y tamaño del sesgo va a depender del proceso de autoselección y los datos

Ley de los grandes números

- La asignación aleatoria no asegura unconfoudedness
- Necesitamos una muestra considerable
- También, por pura chance, puede que nuestros controles y tratamientos difieran significativamente
- Podríamos hacer simulaciones cuando veamos la regresión y podamos añadir otras variables al DGP

Section 6

SUTVA

SUTVA

A grandes rasgos, SUTVA pide:

- No Spillovers
  - Si no, confundiríamos controles con tratamiento
- Misma dósis